Pontificia Universidad JAVERIANA Bogotá	Técnicas de Aprendizaje de maquina Proyecto 1 Profesor: Ing. Julio Omar Palacio Niño, M.Sc. palacio_julio@javeriana.edu.co

Este proyecto de clase representa una oportunidad para que los estudiantes enfrenten un problema complejo de clasificación aplicando técnicas de aprendizaje de maquina sobre un conjunto de datos del mundo real.

Los proyectos deben ser elaborados en grupos de 4 integrantes.

1) Objetivo

Desarrollar un *pipeline* de Machine Learning para predecir el éxito académico o la deserción de estudiantes universitarios, enfocando su esfuerzo analítico en la ingeniería manual de características y la sintonización exhaustiva de hiperparámetros para evitar el sobreajuste.

2) Dataset

https://archive.ics.uci.edu/dataset/697/predict+students+dropout+and+academic+success

3) Restricciones Técnicas

Prohibido el uso de Redes Neuronales Artificiales, ensambles (Random Forest, XGBoost, etc.), Naive Bayes y Análisis de Componentes Principales (PCA).

4) Tareas a desarrollar

1) Análisis Exploratorio y de Dimensionalidad

2) Ejecutar selección de variables argumentada mediante filtros estadísticos (matrices de correlación), regularización L1 (Lasso) o extracción de importancia (*Feature Importances*) a partir de un modelo base.

3) Modelado Dual (Baseline vs. Retador):
   Implementar y contrastar únicamente dos algoritmos, elegidos entre Árbol de Decisión, Regresión Logística, Máquinas de Vectores de Soporte (SVM) o K-Vecinos Más Cercanos (KNN).

a) **Modelo Baseline:** Un algoritmo configurado para máxima interpretabilidad con el cual establecer el rendimiento métrico inicial.
b) **Modelo Retador:** Un algoritmo espacial o no lineal con el cual intentar superar al modelo base, apoyándose estrictamente en la transformación de datos previa.

4) El ajuste manual de hiperparámetros ("ensayo y error") no está permitido. El proceso debe centrarse en:

a) La implementación de GridSearchCV o RandomizedSearchCV acoplado a validación cruzada (K-Fold).
b) La sustentación gráfica obligatoria mediante Curvas de Validación y Curvas de Aprendizaje. Se argumentará analíticamente cómo la alteración de parámetros clave (ej. el margen C y el kernel en SVM, la métrica espacial en KNN, o la poda ccp_alpha en Árboles) controla el sesgo y la varianza del modelo seleccionado.

5) Entrega del proyecto

Informe: Debe entregar un informe que detalle el resultado obtenido, el informe debe contener los siguientes elementos:

- **Abstract**: Resumen del problema abordado, análisis realizado y resultados obtenidos (máximo 150 palabras)
- **Introducción**: Descripción breve de la temática abordada, problema o pregunta que se quiere resolver.
- **Aproximación al problema**: Describa su aproximación para abordar la pregunta utilizando una o más técnicas de aprendizaje supervisado
- **Resultados**: Describa qué encontró al aplicar la técnica al problema.

Presentación (Máximo 10 diapositivas): Presentación que describa temática abordada, pregunta que se quiere resolver, aproximación al problema y resultados obtenidos.

Código: Carpeta con el código desarrollado para la preparación de los datos y la aplicación de las técnicas planteadas.

6) Ponderación

La ponderación del proyecto es la siguiente:

- Reporte: 30%
- Modelo: 50%
- Presentación: 20%